Neumonía en radiografía: precisión frente a energía

LightCNN y ResNet-18 entrenados desde cero, 5 épocas, en el mismo portátil Windows (Intel Core i7-1255U). El conjunto de test tiene 624 imágenes: 234 normales y 390 con neumonía (62,5 %).

Windows · Intel i7-1255U | 10 núcleos · 64 GB · solo CPU | 8 oct 2026 · 15:53–17:35

hf-vision/chest-xray-pneumonia

86,9 %
Accuracy en test, ResNet-18

79,2 %
Accuracy en test, LightCNN

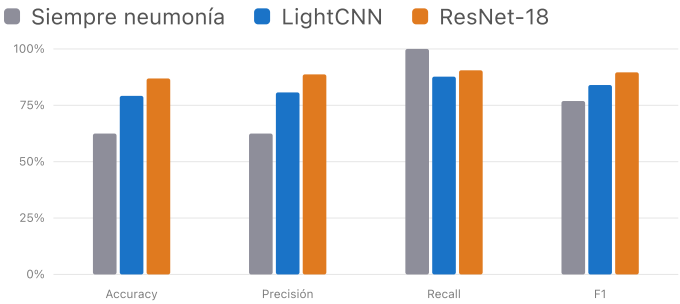
90,5 %
Recall de neumonía, ResNet-18

1,6×
Energía de ResNet-18 respecto a LightCNN

> **El CO_2 de CodeCarbon no es comparable entre los dos runs**
> El seguimiento de LightCNN geolocalizó España (Castilla y León) y el de ResNet-18, Canadá (Quebec). Por eso el CO_2 registrado baja de 3,75 g a 0,13 g aunque ResNet-18 consumió más energía (33,6 Wh frente a 21,3 Wh). Con el factor del primer run (0,176 kg/kWh), ResNet-18 habría emitido unos 5,9 g, 1,6 veces más.

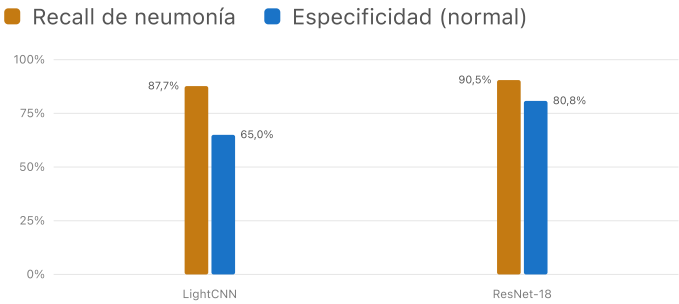
Métricas en el test

Accuracy, precisión, recall y F1



Fuente: experiment_summary.csv · test de 624 imágenes, 8 oct 2026. Precisión, recall y F1 usan neumonía como clase positiva. La serie gris es el clasificador que siempre predice neumonía.

Recall de neumonía frente a especificidad



Especificidad = normales bien clasificados / 234. LightCNN: 152/234. ResNet-18: 189/234, reconstruido desde precisión y recall del resumen (no hay CSV de su matriz).

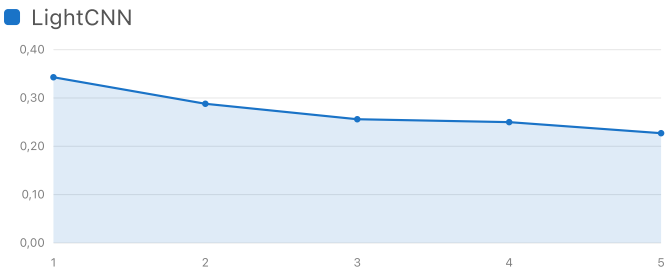
Modelo	Accuracy	Precisión	Recall	F1	Especificidad	Pérdida en test
Siempre neumonía	62,5 %	62,5 %	100 %	76,9 %	0 %	—
LightCNN	79,2 %	80,7 %	87,7 %	84,0 %	65,0 %	0,510
● ResNet-18	86,9 %	88,7 %	90,5 %	89,6 %	80,8 %	0,399

ResNet-18 mejora accuracy y también baja la pérdida en test (0,399 frente a 0,510). Los dos quedan por encima del F1 trivial (76,9 %).

Entrenamiento, época a época

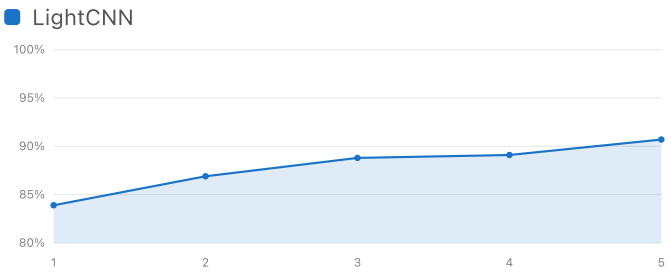
Solo LightCNN tiene historial por época en esta carpeta. No hay ResNet18_history.csv, así que estas curvas no incluyen a ResNet-18.

Pérdida de entrenamiento



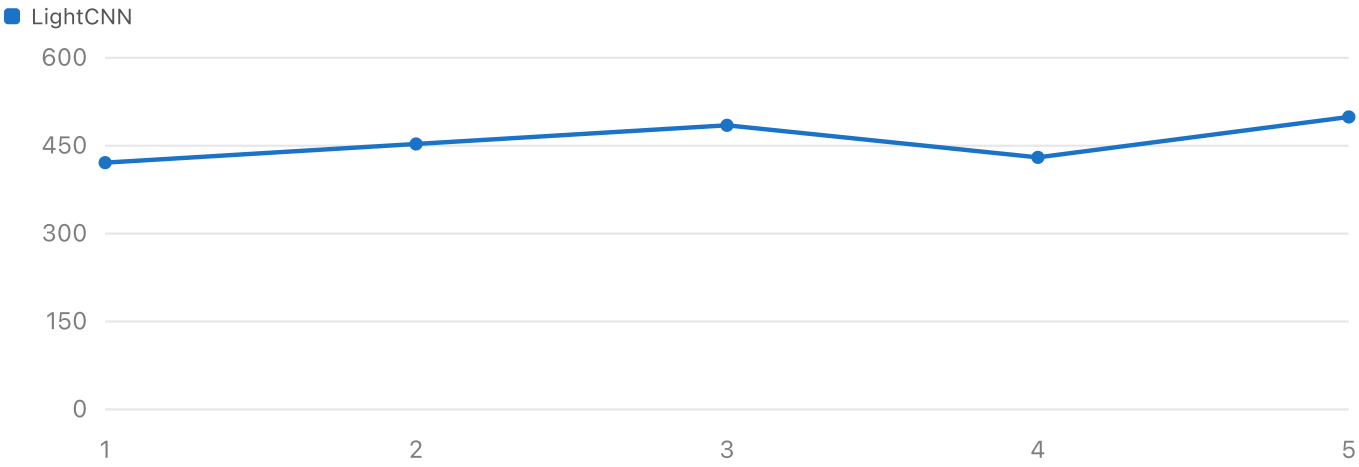
Eje X: época (1–5). Eje Y: pérdida media de entrenamiento (cross-entropy). Fuente: LightCNN_history.csv.

Accuracy de entrenamiento



Eje X: época. Eje Y: accuracy en train (%), eje recortado entre 80 y 100. En la época 5 el train (90,7 %) queda 11,5 puntos por encima del test (79,2 %).

Duración de cada época



Eje X: época. Eje Y: segundos. LightCNN se mueve entre 421 s y 499 s. La suma de épocas (2.288 s) coincide con training_time_seconds.

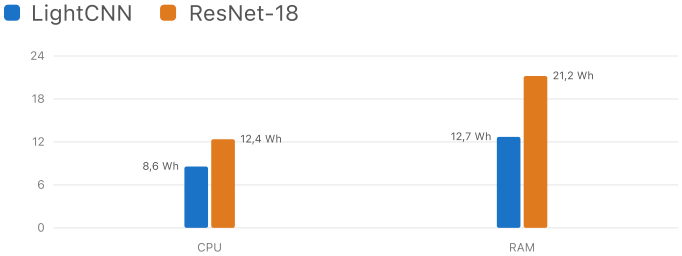
Coste de cómputo y emisiones

ResNet-18 tiene 119 veces más parámetros, pero solo 3,5 veces más FLOPs, 1,7 veces más tiempo y 1,6 veces más energía. El CO_2 registrado no sigue esa proporción: cambió el factor de red entre un run y el otro.

Modelo	Parámetros	FLOPs	Tiempo	Energía	CO_2 registrado
LightCNN	93.954	0,52 G	38,1 min	21,3 Wh	3,75 g
ResNet-18	11,18 millones	1,82 G	63,7 min	33,6 Wh	0,13 g
ResNet-18 / LightCNN	119×	3,5×	1,7×	1,6×	no comparable

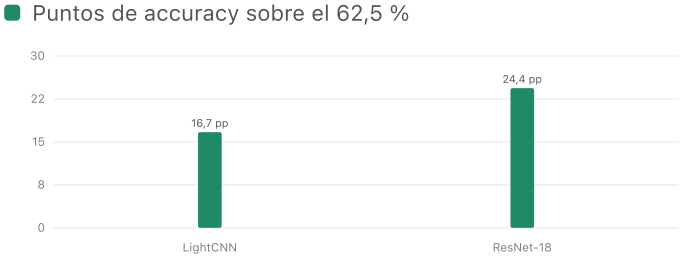
Tiempo: training_time_seconds (2.288 s y 3.820 s). Energía: cpu_energy + ram_energy de codecarbon/emissions.csv, en vatios-hora. CO_2: emissions de ese CSV, tal como se guardó. CodeCarbon 3.3.1, modo machine. LightCNN: Spain / castille and león. ResNet-18: Canada / quebec.

Energía por modelo



Fuente: codecarbon/emissions.csv. La RAM figura a 20 W en los dos runs; la CPU, a 13,5 W (LightCNN) y 13,9 W (ResNet-18).

Accuracy ganada por vatio-hora



Esos puntos cuestan 21,3 Wh y 33,6 Wh. Por vatio-hora, LightCNN gana un poco más de accuracy (0,78 pp/Wh) que ResNet-18 (0,73 pp/Wh).

Matrices de confusión en el test

LightCNN — 624 imágenes

Real \ predicho	Normal	Neumonía
Normal (234)	152	82
Neumonía (390)	48	342

ResNet-18 — 624 imágenes

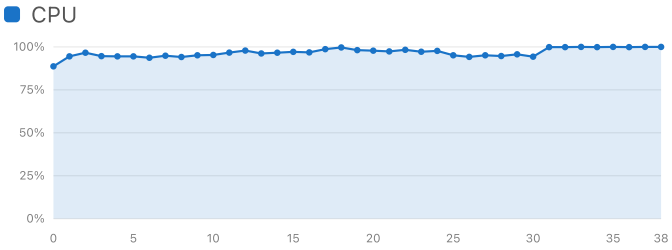
Real \ predicho	Normal	Neumonía
Normal (234)	189	45
Neumonía (390)	37	353

Filas: clase real. Columnas: clase predicha. LightCNN sale de LightCNN_confusion_matrix.csv. ResNet-18 se reconstruye de test_precision y test_recall: 189, 45, 37 y 353, y cierra con la accuracy del resumen (542/624).

CPU y RAM durante el entrenamiento

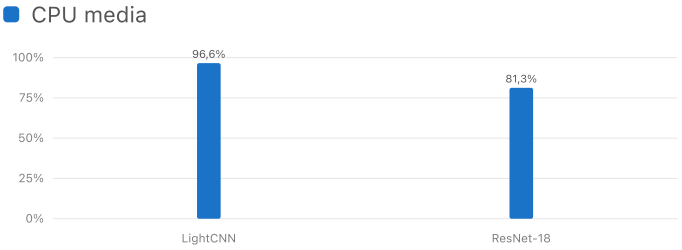
LightCNN deja la CPU en el 96,6 % de media y llega al 100 %. No hay ResNet18_resources.csv: del resumen salen 81,3 % de media y un pico del 100 %. PyTorch es la build de CPU (2.14.1+cpu) y num_workers quedó en 0.

CPU durante LightCNN



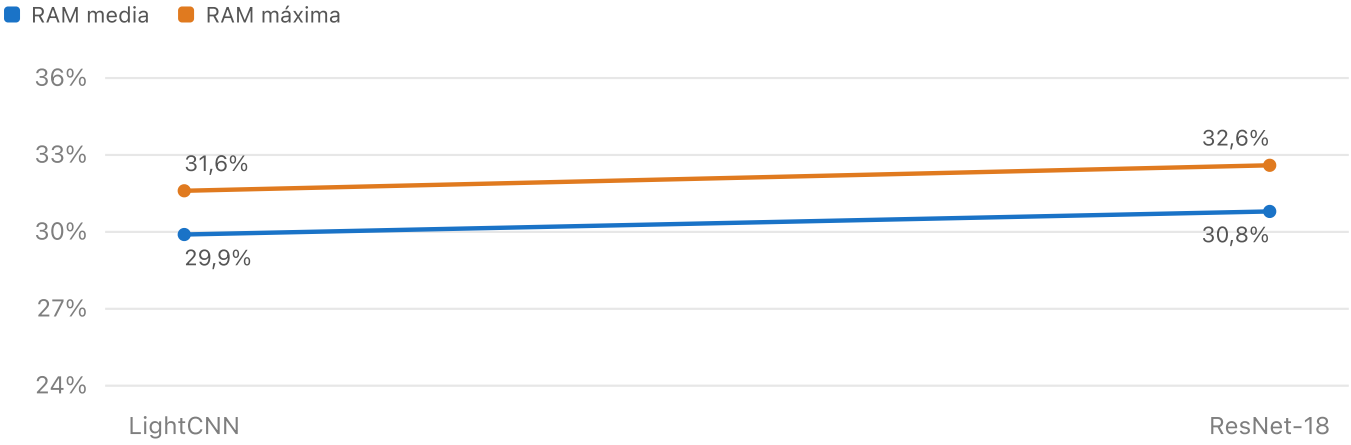
Eje X: minuto desde el inicio. Eje Y: CPU del sistema (%), media de unas 60 muestras por minuto. Media global 96,6 %, pico 100 %. Fuente: LightCNN_resources.csv, 38,2 min.

CPU media de cada entrenamiento



Fuente: cpu_mean_percent de experiment_summary.csv. ResNet-18 no tiene serie temporal en esta carpeta; solo la media y el máximo (100 %).

RAM del sistema



Eje Y: porcentaje de los 63,7 GB, medido con psutil sobre todo el sistema. Se mueve poco (unos 19–21 GB). Las columnas de GPU del monitor están vacías.

Qué se puede concluir

En este portátil, y con cinco épocas sin pesos preentrenados, ResNet-18 es mejor en las cuatro métricas de test: 86,9 % de accuracy, 90,5 % de recall y 80,8 % de especificidad. LightCNN se queda en 79,2 %, 87,7 % y 65,0 %. Los dos se separan del clasificador que siempre predice neumonía (62,5 % de accuracy y 76,9 % de F1): LightCNN suma 16,7 puntos de accuracy y ResNet-18, 24,4 puntos.

LightCNN no repite la clase mayoritaria. Marca como neumonía 82 de las 234 radiografías normales, y su F1 (84,0 %) queda 7 puntos por encima del clasificador trivial (76,9 %). En la época 5 el train (90,7 %) sigue 11,5 puntos por

encima del test. De ResNet-18 no hay curva de entrenamiento en esta carpeta, así que no se puede ver si memoriza el train.

La energía sí se puede comparar: 21,3 Wh y 33,6 Wh. El CO_2 registrado no, porque CodeCarbon cambió de país entre medias. La CPU de LightCNN estuvo casi saturada (media 96,6 %). ResNet-18 bajó a 81,3 % de media y aun así tardó 63,7 min frente a 38,1 min. No hubo GPU. Repetir el script en otro equipo permite comparar ordenadores; estos números no son el coste de un despliegue con GPU ni de pesos de ImageNet.