Neumonía en radiografía: precisión frente a energía

LightCNN y ResNet-18 entrenados desde cero, 5 épocas, en el mismo PC de torre con un Intel Core i7-14700KF. El conjunto de test tiene 624 imágenes: 234 normales y 390 con neumonía (62,5 %).

PC torre · i7-14700KF | 20 núcleos · 31,8 GB · PyTorch en CPU | 25 oct 2026 · 19:40–20:04

hf-vision/chest-xray-pneumonia

83,5 %
Accuracy en test, ResNet-18

76,8 %
Accuracy en test, LightCNN

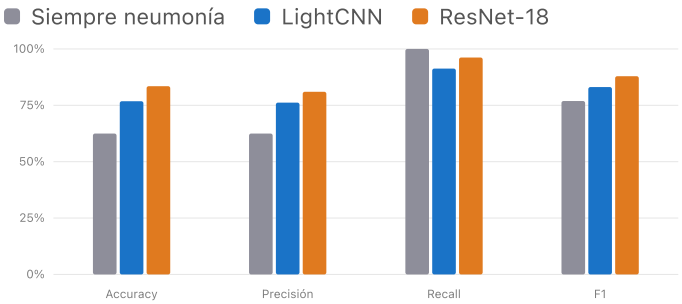
96,2 %
Recall en test, ResNet-18

1,2×
CO_2 de ResNet-18 respecto a LightCNN

> **La RTX 5070 no entrenó los modelos**
> PyTorch es la build de CPU (2.14.1+cpu) y el monitor de recursos deja vacías las columnas de GPU. CodeCarbon sí ve la RTX 5070, pero en reposo: suma 1,20 Wh en LightCNN y 0,95 Wh en ResNet-18. La CPU, en cambio, se queda en torno al 74 % de los 28 hilos y aporta casi toda la energía.

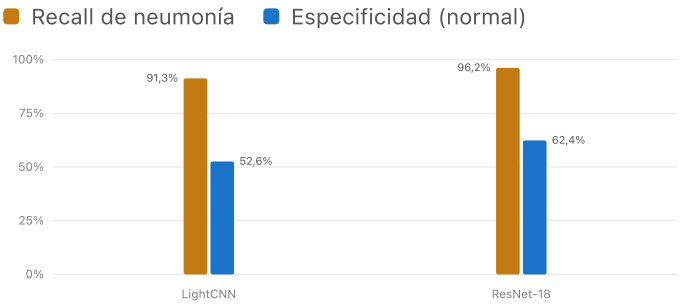
Métricas en el test

Accuracy, precisión, recall y F1



Fuente: experiment_summary.csv · test de 624 imágenes, 25 oct 2026. Precisión, recall y F1 usan neumonía como clase positiva. La serie gris es el clasificador que siempre predice neumonía.

Recall de neumonía frente a especificidad



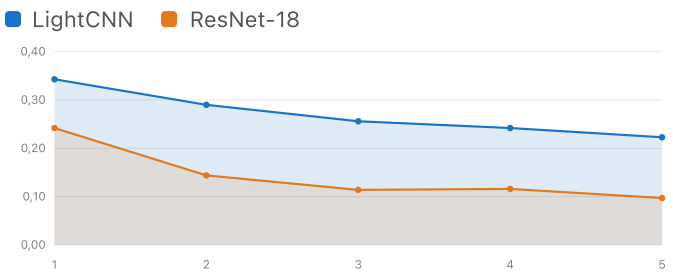
Fuente: matrices de confusión del test. Especificidad = normales bien clasificados / 234. Los dos modelos detectan la mayoría de las neumonías y siguen fallando en las normales: 111 y 88 de 234.

Modelo	Accuracy	Precisión	Recall	F1	Especificidad	Pérdida en test
Siempre neumonía	62,5 %	62,5 %	100 %	76,9 %	0 %	—
LightCNN	76,8 %	76,2 %	91,3 %	83,1 %	52,6 %	0,562
● ResNet-18	83,5 %	81,0 %	96,2 %	87,9 %	62,4 %	0,507

ResNet-18 mejora la accuracy y también baja la pérdida en test (0,507 frente a 0,562). LightCNN queda 14,3 puntos por encima del clasificador que siempre predice neumonía; su F1 (83,1 %) supera el 76,9 % de esa línea de base.

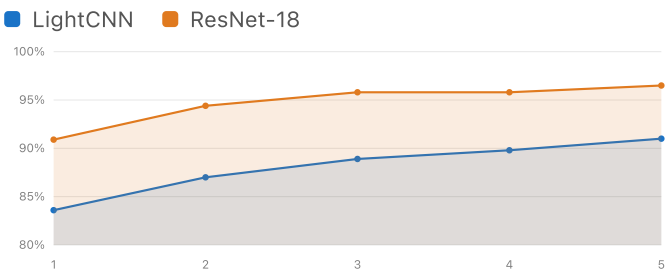
Entrenamiento, época a época

Pérdida de entrenamiento



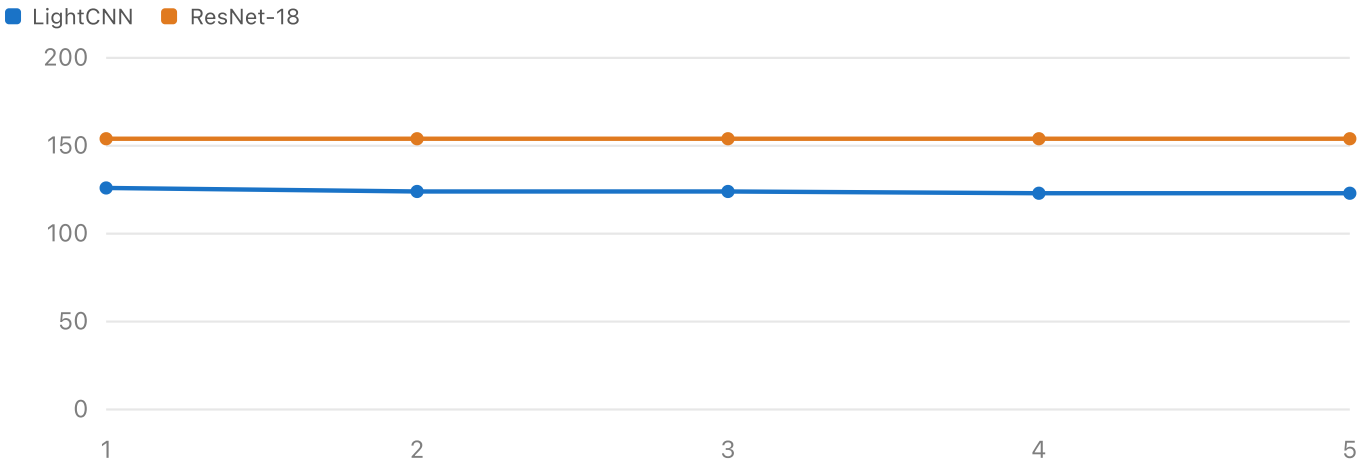
Eje X: época (1–5). Eje Y: pérdida media de entrenamiento (cross-entropy). Fuente: LightCNN_history.csv y ResNet18_history.csv.

Accuracy de entrenamiento



Eje X: época. Eje Y: accuracy en el conjunto de train (%), eje recortado entre 80 y 100 para ver la pendiente. En la época 5 el train queda 14 puntos (LightCNN) y 13 puntos (ResNet-18) por encima del test.

Duración de cada época



Eje X: época. Eje Y: segundos. LightCNN se mantiene entre 123 s y 126 s. ResNet-18, en 154 s. Fuente: columnas time_seconds de los historiales.

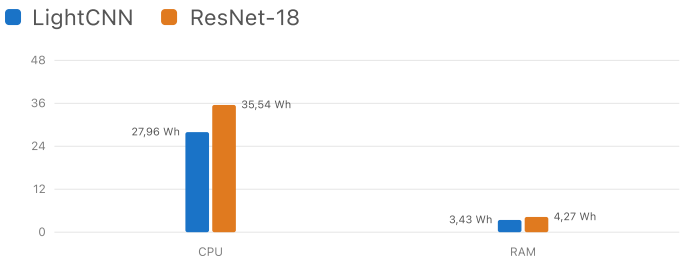
Coste de cómputo y emisiones

ResNet-18 tiene 119 veces más parámetros, pero solo 3,5 veces más FLOPs, 1,2 veces más tiempo y 1,2 veces más CO_2. El tiempo y la energía crecen con el cálculo por imagen, no con el número de pesos.

Modelo	Parámetros	FLOPs	Tiempo	Energía	CO_2
LightCNN	93.954	0,52 G	10,3 min	31,4 Wh	5,89 g
ResNet-18	11,18 millones	1,82 G	12,8 min	39,8 Wh	7,33 g
ResNet-18 / LightCNN	119×	3,5×	1,2×	1,3×	1,2×

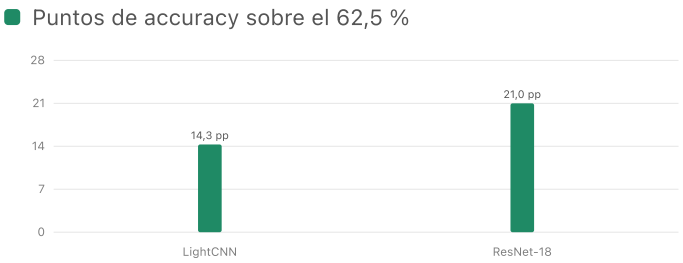
Tiempo: training_time_seconds de experiment_summary.csv (620 s y 770 s). Energía: cpu_energy + ram_energy de codecarbon/emissions.csv, en vatios-hora, sin la GPU en reposo. CO_2: codecarbon_emissions_value, factor de red de España (Illes Balears) en los dos entrenamientos. CodeCarbon 3.3.2, modo machine.

Energía por modelo



Fuente: codecarbon/emissions.csv. La CPU ronda 163 W (LightCNN) y 166 W (ResNet-18). La RAM entra como 20 W fijos de CodeCarbon.

Accuracy ganada por vatio-hora



Esos puntos cuestan 31,4 Wh y 39,8 Wh. Por vatio-hora, ResNet-18 gana más accuracy (0,53 pp/Wh) que LightCNN (0,45 pp/Wh). También gana recall.

Matrices de confusión en el test

LightCNN — 624 imágenes

Real \ predicho	Normal	Neumonía
Normal (234)	123	111
Neumonía (390)	34	356

ResNet-18 — 624 imágenes

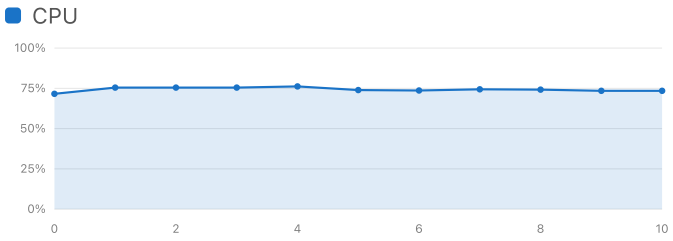
Real \ predicho	Normal	Neumonía
Normal (234)	146	88
Neumonía (390)	15	375

Filas: clase real. Columnas: clase predicha. Etiqueta 0 = normal, 1 = neumonía, coherente con la precisión y el recall del resumen. Fuente: LightCNN_confusion_matrix.csv y ResNet18_confusion_matrix.csv.

CPU y RAM durante el entrenamiento

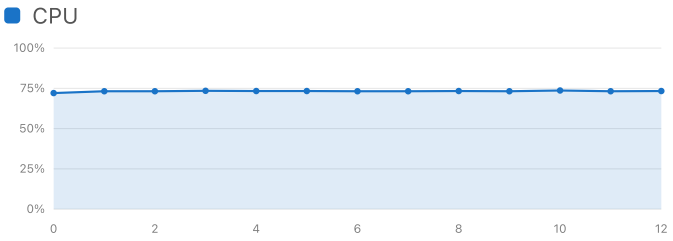
Los dos modelos dejan la CPU en torno al 74 % de los 28 hilos. Aquí el chip sí trabaja. Aun así la GPU no participa, porque el script solo elige CUDA o CPU y esta instalación de PyTorch no tiene CUDA. num_workers quedó en 0.

CPU durante LightCNN



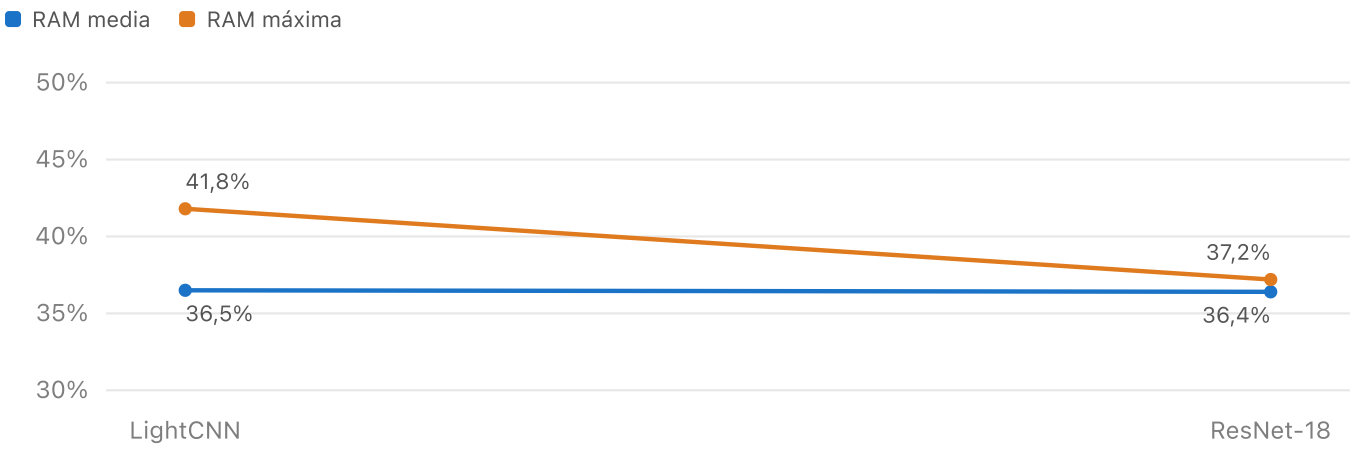
Eje X: minuto desde el inicio del entrenamiento. Eje Y: CPU del sistema (%), media de unas 60 muestras por minuto. Media global 74,4 %, pico 90,6 %. Fuente: LightCNN_resources.csv, 10,3 min.

CPU durante ResNet-18



Eje X: minuto desde el inicio. Eje Y: CPU (%). Media global 73,2 %, pico 82,3 %. Fuente: ResNet18_resources.csv, 12,8 min.

RAM del sistema



Eje Y: porcentaje de los 31,8 GB, recortado entre 30 y 50. Medido con psutil sobre todo el sistema, no solo el proceso. Son unos 11,6 GB de media. Las columnas de GPU del monitor están vacías.

Qué se puede concluir

En esta torre, y con cinco épocas sin pesos preentrenados, ResNet-18 es el mejor clasificador en accuracy, recall, F1 y especificidad: 83,5 %, 96,2 %, 87,9 % y 62,4 %. Deja escapar 15 neumonías frente a 34 de LightCNN, y emite algo más de CO_2 (7,33 g frente a 5,89 g).

LightCNN sí se separa del clasificador que siempre dice neumonía: 14,3 puntos de accuracy y un F1 de 83,1 % frente a 76,9 %. Aun así marca como neumonía 111 de las 234 radiografías normales. La accuracy de entrenamiento en la época 5 (91,0 % y 96,5 %) queda 14 y 13 puntos por encima del test: los dos modelos memorizan parte del train.

La comparación de energía es válida entre estos dos entrenamientos en CPU, en el mismo equipo y con el mismo factor de red (Illes Balears). No mide un despliegue con la RTX 5070: esa GPU estaba instalada y PyTorch no la usó. La potencia de CPU fue alta y estable (163–166 W) porque el chip se mantuvo cerca del 74 %. Repetir el mismo script en otro ordenador permite comparar equipos; pasar a CUDA o a pesos de ImageNet cambiaría accuracy, tiempo y emisiones a la vez.