Neumonía en radiografía: precisión frente a energía

LightCNN y ResNet-18 entrenados desde cero, 5 épocas, en el mismo MacBook Air M5. El conjunto de test tiene 624 imágenes: 234 normales y 390 con neumonía (62,5 %).

MacBook Air · Apple M5 | 10 núcleos · 24 GB · solo CPU | 8 oct 2026 · 16:06–16:33 | hf-vision/chest-xray-pneumonia

73,9 %
Accuracy en test, ResNet-18

67,6 %
Accuracy en test, LightCNN

97,2 %
Recall de neumonía, LightCNN

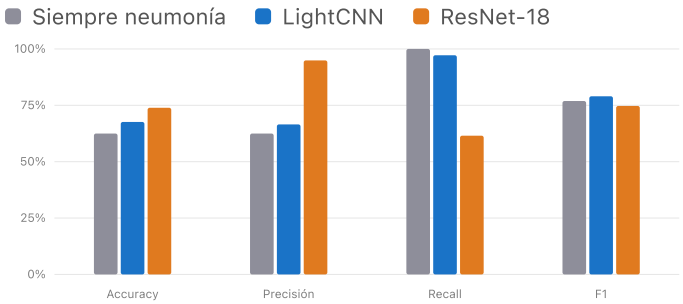
2,0×
CO_2 de ResNet-18 respecto a LightCNN

LightCNN casi repite la clase mayoritaria

Predecir siempre neumonía acertaría el 62,5 % y tendría un F1 de 76,9 %. LightCNN sube la accuracy solo 5,1 puntos (67,6 %) y el F1 a 79,0 %, porque marca como neumonía 191 de las 234 radiografías normales. ResNet-18 sí se separa de esa línea de base (+11,4 puntos de accuracy), a costa de no detectar 150 de las 390 neumonías.

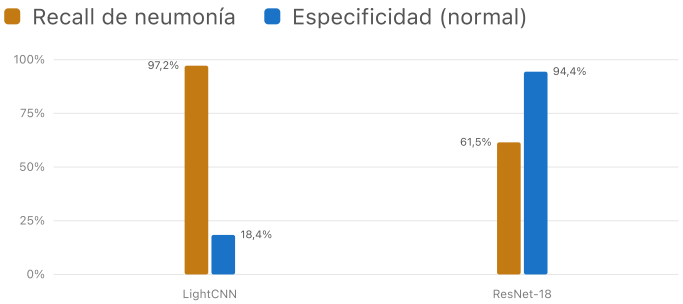
Métricas en el test

Accuracy, precisión, recall y F1



Fuente: experiment_summary.csv · test de 624 imágenes, 8 oct 2026. Precisión, recall y F1 usan neumonía como clase positiva. La serie gris es el clasificador que siempre predice neumonía.

Recall de neumonía frente a especificidad



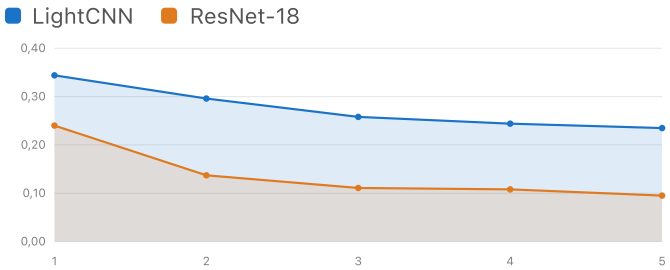
Fuente: matrices de confusión del test. Especificidad = normales bien clasificados / 234. LightCNN detecta casi todas las neumonías y confunde el 81,6 % de las normales.

Modelo	Accuracy	Precisión	Recall	F1	Especificidad	Pérdida en test
Siempre neumonía	62,5 %	62,5 %	100 %	76,9 %	0 %	—
● LightCNN	67,6 %	66,5 %	97,2 %	79,0 %	18,4 %	0,804
● ResNet-18	73,9 %	94,9 %	61,5 %	74,7 %	94,4 %	1,060

ResNet-18 tiene mejor accuracy y peor pérdida en test (1,060 frente a 0,804): cuando se equivoca, lo hace con más confianza.

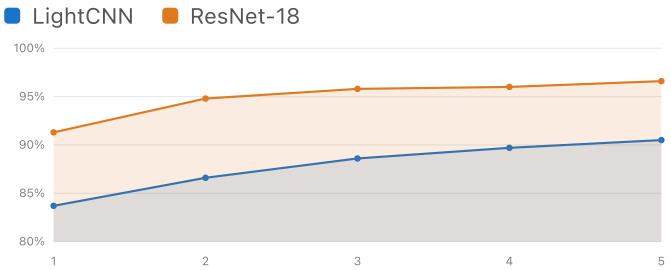
Entrenamiento, época a época

Pérdida de entrenamiento



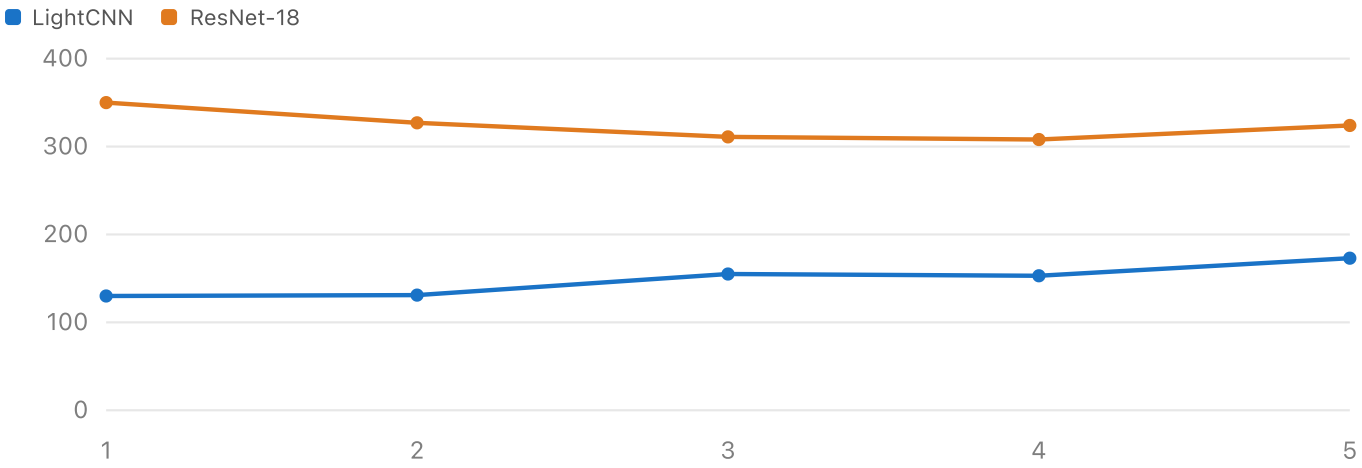
Eje X: época (1–5). Eje Y: pérdida media de entrenamiento (cross-entropy). Fuente: LightCNN_history.csv y ResNet18_history.csv.

Accuracy de entrenamiento



Eje X: época. Eje Y: accuracy en el conjunto de train (%), eje recortado entre 80 y 100 para ver la pendiente. En la época 5 el train está 23 puntos por encima del test en los dos modelos.

Duración de cada época



Eje X: época. Eje Y: segundos. LightCNN pasa de 130 s a 173 s (+33 % en la última época). ResNet-18 se mantiene entre 308 s y 350 s. Fuente: columnas time_seconds de los historiales.

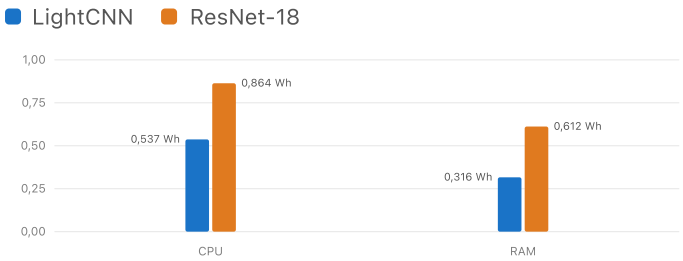
Coste de cómputo y emisiones

ResNet-18 tiene 119 veces más parámetros, pero solo 3,5 veces más FLOPs y el doble de emisiones. El tiempo y la energía crecen con el cálculo por imagen, no con el número de pesos.

Modelo	Parámetros	FLOPs	Tiempo	Energía	CO_2
LightCNN	93.954	0,52 G	12,4 min	0,85 Wh	0,129 g
ResNet-18	11,18 millones	1,82 G	27,0 min	1,48 Wh	0,257 g
ResNet-18 / LightCNN	119×	3,5×	2,2×	1,7×	2,0×

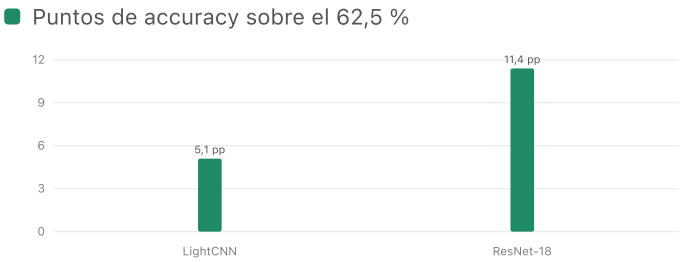
Tiempo: training_time_seconds de experiment_summary.csv (742 s y 1.620 s). Energía: cpu_energy + ram_energy de codecarbon/emissions.csv, en vatios-hora. CO_2: codecarbon_emissions_value, factor de red de España (Illes Balears). CodeCarbon 3.2.3, modo machine.

Energía por modelo



Fuente: codecarbon/emissions.csv. La RAM aporta unos 6 W constantes en los dos entrenamientos; la CPU, 9,8 W (LightCNN) y 8,1 W (ResNet-18).

Accuracy ganada por vatio-hora



Esos puntos cuestan 0,85 Wh y 1,48 Wh. Por vatio-hora, ResNet-18 gana más accuracy (7,7 pp/Wh) que LightCNN (6,0 pp/Wh). No gana recall.

Matrices de confusión en el test

LightCNN — 624 imágenes

Real \ predicho	Normal	Neumonía
Normal (234)	43	191
Neumonía (390)	11	379

ResNet-18 — 624 imágenes

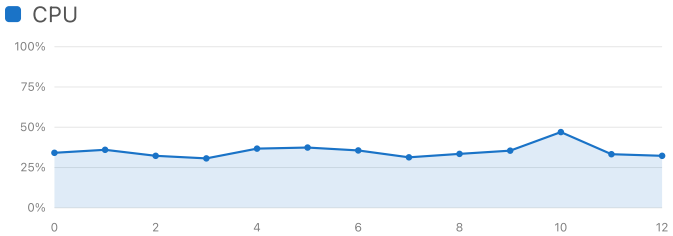
Real \ predicho	Normal	Neumonía
Normal (234)	221	13
Neumonía (390)	150	240

Filas: clase real. Columnas: clase predicha. Etiqueta 0 = normal, 1 = neumonía, coherente con la precisión y el recall del resumen. Fuente: LightCNN_confusion_matrix.csv y ResNet18_confusion_matrix.csv.

CPU y RAM durante el entrenamiento

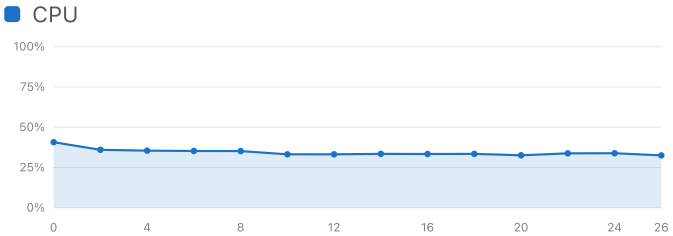
Los dos modelos dejan la CPU en torno al 35 % de los 10 núcleos. El cuello de botella no es saturar el chip: PyTorch no usó la GPU del M5 (el script solo elige CUDA o CPU) y num_workers quedó en 0.

CPU durante LightCNN



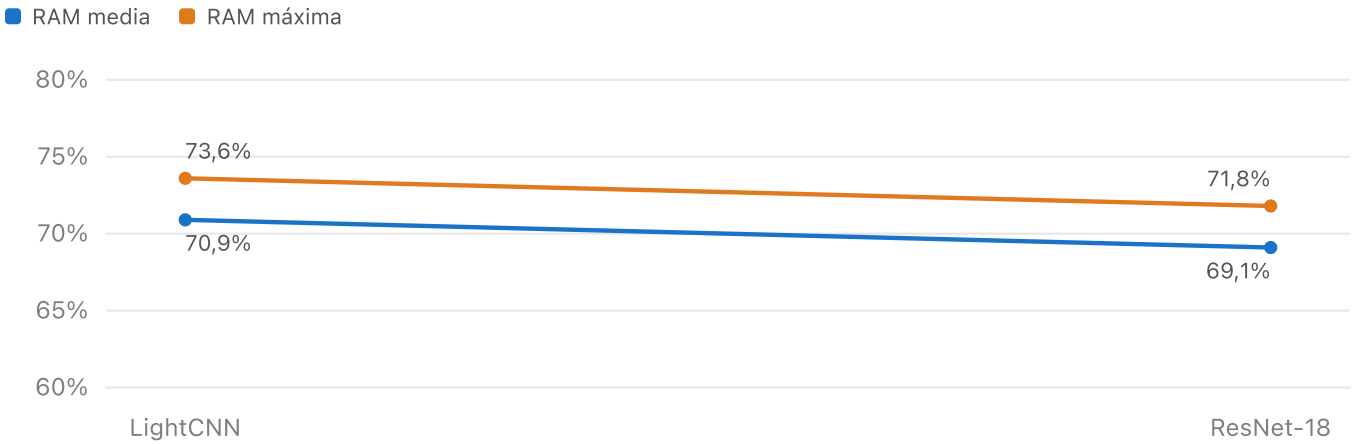
Eje X: minuto desde el inicio del entrenamiento. Eje Y: CPU del sistema (%), media de ~60 muestras por minuto. Media global 35,2 %, pico 76,2 %. Fuente: LightCNN_resources.csv.

CPU durante ResNet-18



Eje X: minuto (cada punto agrupa dos minutos, salvo el 0). Eje Y: CPU (%). Media global 34,5 %, pico 86,0 %. Fuente: ResNet18_resources.csv, 27,1 min.

RAM del sistema



Eje Y: porcentaje de los 24 GB, medido con psutil sobre todo el sistema, no solo el proceso. Se mueve poco (unos 16,6–17,7 GB). Las columnas de GPU del monitor están vacías: no hay GPU NVIDIA.

Qué se puede concluir

En este Mac, y con cinco épocas sin pesos preentrenados, ResNet-18 es el mejor clasificador global: 73,9 % de accuracy y 94,4 % de especificidad. LightCNN es el más sensible: deja escapar 11 neumonías frente a 150, y emite la mitad de CO_2 (0,129 g frente a 0,257 g).

Esa sensibilidad de LightCNN no demuestra que haya aprendido la imagen. Su F1 (79,0 %) está a 2 puntos del clasificador trivial que siempre dice neumonía (76,9 %). La accuracy de entrenamiento en la época 5 (90,5 % y 96,6 %) queda unos 23 puntos por encima del test en los dos modelos: ambos memorizan el train.

La comparación de energía es válida entre estos dos entrenamientos en CPU, no como coste de un despliegue con GPU. La potencia de CPU fue baja y estable (8–10 W) porque el chip no pasó del 35 % de media. Repetir el mismo script en otro ordenador sí permite comparar equipos; cambiar a MPS o a pesos de ImageNet cambiaría accuracy, tiempo y emisiones a la vez.